

Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и технологий
Высшая школа искусственного интеллекта

КУРСОВОЙ ПРОЕКТ

Оптимизация SQL-запросов в СУБД Oracle 11g

по дисциплине «Программирование и оптимизация баз данных»

Выполнил
студент гр 3530203/60101

В.К. Фурман

Руководитель
доцент

О.Ю. Сабинин

«___» _____ 202__ г.

Санкт-Петербург

2021

СОДЕРЖАНИЕ

Введение	3
Описание окружения	4
Глава 1. Задача «Процент мужчин/женщин в заданную дату (OE)»	5
1.1. Описание задачи	5
1.2. Составленный запрос	5
1.3. Первая оптимизация (function-based индекс)	6
1.4. Вторая оптимизация (bitmap индекс)	7
Глава 2. Задача «Имена сотрудников, встречающиеся более 2-ух раз (HR)»	9
2.1. Описание задачи	9
2.2. Составленный запрос	9
2.3. Первая оптимизация (переписывание запроса)	10
2.4. Вторая оптимизация (материализованное представление)	11
Глава 3. Задача «Вывод групп с отличниками и должниками (STUDENT)»	13
3.1. Описание задачи	13
3.2. Составленный запрос	13
3.3. Первая оптимизация (bitmap индекс)	16
3.4. Вторая оптимизация (индексно-организованная таблица)	17
Глава 4. Задача «Клиент, сделавший покупку на максимальную сумму (SH)»	19
4.1. Описание задачи	19
4.2. Составленный запрос	19
4.3. Первая оптимизация (индексно-организованная таблица)	20
4.4. Вторая оптимизация (композитный B-tree индекс)	22
Глава 5. Задача «Список сотрудников по должностям и зарплатам (HR)» ...	24
5.1. Описание задачи	24
5.2. Составленный запрос	24
5.3. Первая оптимизация (материализованное представление)	26
5.4. Вторая оптимизация (композитный bitmap индекс)	27
Заключение	29
Список использованных источников	30

ВВЕДЕНИЕ

Оптимизация запросов — важная часть администрирования баз данных. От скорости выполнения зависит скорость работы всего приложения (если база данных используется для какого-либо приложения). К примеру, в интернет-магазине, чем дольше пользователь ждёт, пока загрузятся данные, тем выше вероятность, что он покинет сайт в пользу конкурента. Оптимизация так же помогает избежать траты на излишнюю покупку железа, которое приобретают, чтобы ускорить работу базы данных. Поэтому крайне важно научиться анализировать запросы на возможность их оптимизации.

Целью данной работы является практика оптимизирования запросов в СУБД Oracle. Конкретно — оптимизироваться будет стоимость запросов (*cost*), которая вычисляется по формуле (1) [3].

$$\text{cost} = \frac{(\#SRds \cdot \text{sreadtim}) + (\#MRds \cdot \text{mreadtim}) + (\#cpuCycles/\text{cpuSpeed})}{\text{sreadtim}}, \quad (1)$$

где

- SRDs — количество одноблочных чтений.
- sreadtim — время на одно одноблочное чтение.
- #MRDs — количество многоблочных чтений.
- mreadtim — время одно на многоблочное чтение.
- #cpuCycles — количество циклов CPU. Включает в себя стоимость CPU-обработки (чистая стоимость CPU) и стоимость извлечения данных (стоимость *buffer cache get* в CPU).
- cpuSpeed — количество CPU-циклов в секунду.

Порядок выполнения работы будет следующим:

1. Написать SQL-запрос для каждой задачи.
2. Проанализировать планы выполнения, статистики, а также сами запросы на возможные варианты оптимизаций.
3. Использовать как минимум 2 оптимизации на каждый запрос (причём одна оптимизация может быть использована не более, чем дважды за всю работу).
4. Оптимизация может считаться успешной при уменьшении стоимости (*cost*).

ОПИСАНИЕ ОКРУЖЕНИЯ

Используется база данных Oracle версии Oracle Database 21c Express Edition Release 21.0.0.0.0 – Production Version 21.3.0.0.0. Схемы создавались в Portable Database [2] хепdb1, поэтому строки подключения имели вид: CONNECT hr/PASSWORD@хепdb1.

Стандартные схемы Oracle (HR, OE и т. д.) были взяты из официального репозитория Oracle [1]. Схема STUDENT была взята с учебного курса «Программирование и оптимизация баз данных» [5].

Перед каждым выполнением SQL-запроса выполняется очистка Buffer Cache и Shared Pool с помощью первых двух команд ниже. После чего выполняется запрос с выводом плана.

```
alter system flush shared_pool;
alter system flush buffer_cache;
set autotrace on
@task-/*НОМЕР-ЗАДАНИЯ*/.sql
set autotrace off
```

Для схем HR, OE и STUDENT были сгенерированы данные (код генерации и SQL-скрипты для вставки доступны для скачивания в репозитории [4]). После добавления данных выполняется сбор статистики для задействованных таблиц, пример для сбора статистики таблицы HR.EMPLOYEES показан ниже.

```
EXEC DBMS_STATS.GATHER_TABLE_STATS('HR', 'EMPLOYEES');
```

Результаты запросов показываются для исходных данных (без сгенерированных), так как некоторые запросы выводят сотни строк со сгенерированными данными. Все планы, включённые в данную работу, показываются для таблиц со сгенерированными данными.

Проверка наличия индексов в таблицах делалась следующим образом:

```
SELECT
  CAST(ind.table_name AS VARCHAR2(36)) AS "Table",
  CAST(ind.index_name AS VARCHAR2(36)) AS "Index name",
  CAST(col.column_name AS VARCHAR2(36)) AS "Column",
  CAST(ind.index_type AS VARCHAR2(36)) AS "Index type"
FROM user_indexes ind
  JOIN user_ind_columns col
    ON ind.index_name = col.index_name
ORDER BY 1, 2, 3, 4;
```

ГЛАВА 1. ЗАДАЧА «ПРОЦЕНТ МУЖЩИН/ЖЕНЩИН В ЗАДАННУЮ ДАТУ (OE)»

1.1. Описание задачи

Используются таблицы схемы OE. Вывести процентное соотношение мужчин и женщин, разместивших заказы в заданную дату. Если один и тот же человек разместил несколько заказов в заданную дату, он должен быть учтён только один раз. В результате должно быть три столбца: дата, процент мужчин и процент женщин.

1.2. Составленный запрос

```
ACCEPT date CHAR PROMPT 'Enter date in format dd-mm-yyyy (e.g. 29-06-2007): '

SELECT
  '&date' AS "Date",
  100
    * COUNT(CASE WHEN oe.customers.gender = 'M' THEN 1 END)
    / COUNT(*)
  AS "Males (%)",
  100
    * COUNT(CASE WHEN oe.customers.gender = 'F' THEN 1 END)
    / COUNT(*)
  AS "Females (%)"
FROM
  oe.customers
  JOIN (
    SELECT DISTINCT customer_id
    FROM oe.orders
    WHERE
      TRUNC(order_date, 'dd')
        = TRUNC(TO_DATE('&date', 'dd-mm-yyyy'), 'dd')
  ) customer_ids
ON oe.customers.customer_id = customer_ids.customer_id;
```

Рис.1.1. Запрос для задачи №1

Date	Males (%)	Females (%)
29-06-2007	75	25

Рис.1.2. Результат запроса для даты «29-06-2007»

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0	SELECT STATEMENT		1	20	56 (8)	00:00:01
1	SORT AGGREGATE		1	20		
* 2	HASH JOIN		379	7580	56 (8)	00:00:01
3	VIEW		379	4927	29 (14)	00:00:01
4	HASH UNIQUE		379	4927	29 (14)	00:00:01
* 5	TABLE ACCESS FULL	ORDERS	385	5005	28 (11)	00:00:01
6	TABLE ACCESS FULL	CUSTOMERS	10319	72233	27 (0)	00:00:01

Predicate Information (identified by operation id):

```

2 - access("CUSTOMERS"."CUSTOMER_ID"="CUSTOMER_IDS"."CUSTOMER_ID")
5 - filter(TRUNC(INTERNAL_FUNCTION("ORDER_DATE"),'fmdd')=TO_DATE('
      2007-06-29 00:00:00', 'yyyy-mm-dd hh24:mi:ss') AND "CUSTOMER_ID">0)

```

Note

- this is an adaptive plan

Statistics

```

2732 recursive calls
0 db block gets
3905 consistent gets
478 physical reads
0 redo size
776 bytes sent via SQL*Net to client
52 bytes received via SQL*Net from client
2 SQL*Net roundtrips to/from client
248 sorts (memory)
0 sorts (disk)
1 rows processed

```

Рис.1.3. План выполнения запроса

1.3. Первая оптимизация (function-based индекс)

Обратим внимание на то, что в исходном запросе используется сравнение даты, использующее функцию TRUNC. Создадим function-based индекс на эту функцию на столбец order_date.

```
CREATE INDEX orders_order_date_fnidx ON oe.orders (TRUNC(order_date, 'dd'));
```

Рис.1.4. Создание function-based индекса

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0	SELECT STATEMENT		1	20	48 (5)	00:00:01
1	SORT AGGREGATE		1	20		
* 2	HASH JOIN		250	5000	48 (5)	00:00:01
3	VIEW		250	3250	20 (5)	00:00:01
4	HASH UNIQUE		250	3500	20 (5)	00:00:01

```

|* 5 |      TABLE ACCESS BY INDEX ROWID BATCHED| ORDERS          | 253 | 3542 | 19 (0) | 00:00:01 |
|* 6 |      INDEX RANGE SCAN                    | ORDERS_ORDER_DATE_FNIDX | 101 |      | 1 (0) | 00:00:01 |
| 7 |      TABLE ACCESS FULL                  | CUSTOMERS              | 10319 | 72233 | 27 (0) | 00:00:01 |
-----

```

Predicate Information (identified by operation id):

```

2 - access("CUSTOMERS"."CUSTOMER_ID"="CUSTOMER_IDS"."CUSTOMER_ID")
5 - filter("CUSTOMER_ID">0)
6 - access(TRUNC(INTERNAL_FUNCTION("ORDER_DATE"),'fmd')=TO_DATE(' 2007-06-29 00:00:00', 'yyyy-mm-dd
    hh24:mi:ss'))

```

Statistics

```

2992 recursive calls
5 db block gets
4135 consistent gets
491 physical reads
852 redo size
776 bytes sent via SQL*Net to client
52 bytes received via SQL*Net from client
2 SQL*Net roundtrips to/from client
271 sorts (memory)
0 sorts (disk)
1 rows processed

```

Рис.1.5. План выполнения оптимизированного запроса

Как можно увидеть по плану, cost уменьшился на ~ 14% (56 → 48), поменялись также статистики (не в лучшую сторону):

- recursive calls — 2732 → 2992,
- db block gets — 0 → 5,
- consistent gets — 3905 → 4135,
- physical reads — 478 → 491,
- redo size — 0 → 852,
- sorts (memory) — 248 → 271.

1.4. Вторая оптимизация (bitmap индекс)

Обратим также внимание на то, что столбец gender таблицы customers имеет всего 2 значения — «F» и «M», из чего напрашивается желание создать bitmap-индекс на этот столбец.

```
CREATE BITMAP INDEX customers_gender_btmdx ON oe.customers (gender);
```

Рис.1.6. Создание bitmap индекса

```

-----
| Id | Operation                      | Name              | Rows  | Bytes | Cost (%CPU)| Time      |
-----
| 0 | SELECT STATEMENT                |                   | 1      | 20    | 51 (8) | 00:00:01 |
| 1 | SORT AGGREGATE                  |                   | 1      | 20    |          |          |
|* 2 | HASH JOIN                       |                   | 379    | 7580  | 51 (8) | 00:00:01 |
| 3 | VIEW                            |                   | 379    | 4927  | 29 (14) | 00:00:01 |
-----

```

	4		HASH UNIQUE				379		4927		29	(14)		00:00:01	
*	5		TABLE ACCESS FULL		ORDERS		385		5005		28	(11)		00:00:01	
	6		VIEW		index\$_join\$_001		10319		72233		22	(0)		00:00:01	
*	7		HASH JOIN												
	8		BITMAP CONVERSION TO ROWIDS				10319		72233		1	(0)		00:00:01	
	9		BITMAP INDEX FULL SCAN		CUSTOMERS_GENDER_BTMDIX										
	10		INDEX FAST FULL SCAN		CUSTOMERS_PK		10319		72233		26	(0)		00:00:01	

Predicate Information (identified by operation id):

```

2 - access("CUSTOMERS"."CUSTOMER_ID"="CUSTOMER_IDS"."CUSTOMER_ID")
5 - filter(TRUNC(INTERNAL_FUNCTION("ORDER_DATE"),'fmd')=TO_DATE(' 2007-06-29 00:00:00',
'syyy-mm-dd hh24:mi:ss') AND "CUSTOMER_ID">0)
7 - access(ROWID=ROWID)

```

Statistics

```

2988 recursive calls
0 db block gets
4087 consistent gets
432 physical reads
0 redo size
776 bytes sent via SQL*Net to client
52 bytes received via SQL*Net from client
2 SQL*Net roundtrips to/from client
274 sorts (memory)
0 sorts (disk)
1 rows processed

```

Рис.1.7. План выполнения оптимизированного запроса

В плане видим, что стоимость (cost) уменьшилась на $\sim 8\%$ ($56 \rightarrow 51$).
Посмотрим, как поменялись статистики (в основном, в худшую сторону):

- recursive calls — $2732 \rightarrow 2988$,
- consistent gets — $3905 \rightarrow 4087$,
- physical reads — $478 \rightarrow 432$,
- sorts (memory) — $248 \rightarrow 274$.

ГЛАВА 2. ЗАДАЧА «ИМЕНА СОТРУДНИКОВ, ВСТРЕЧАЮЩИЕСЯ БОЛЕЕ 2-УХ РАЗ (HR)»

2.1. Описание задачи

Используются таблицы схемы HR. Вывести имена сотрудников, встречающиеся в таблице сотрудников не менее трех раз и не являющиеся именами руководителей подразделений компании или именами непосредственных руководителей кого-либо. В результате должны быть выведены только имена сотрудников, причём каждое — только один раз.

2.2. Составленный запрос

```
SELECT first_name
FROM hr.employees
GROUP BY first_name
HAVING COUNT(*) >= 3
MINUS
SELECT hr.employees.first_name
FROM hr.employees
JOIN (
    SELECT manager_id
    FROM hr.employees
    WHERE manager_id IS NOT NULL
    UNION ALL
    SELECT manager_id
    FROM hr.departments
    WHERE manager_id IS NOT NULL
) manager_ids
ON hr.employees.employee_id = manager_ids.manager_id;
```

Рис.2.1. Запрос для задачи №2

```
FIRST_NAME
-----
David
Peter
```

Рис.2.2. Результат запроса

```
-----
| Id | Operation | Name | Rows | Bytes | Cost (%CPU) | Time |
```

	0		SELECT STATEMENT				5		610		107		(4)		00:00:01	
	1		MINUS HASH													
*	2		HASH GROUP BY				5		35		17		(18)		00:00:01	
	3		INDEX FAST FULL SCAN		EMP_NAME_IX		10107		70749		14		(0)		00:00:01	
*	4		HASH JOIN SEMI				23		575		90		(2)		00:00:01	
	5		TABLE ACCESS FULL		EMPLOYEES		10107		118K		68		(0)		00:00:01	
	6		VIEW				10117		128K		21		(0)		00:00:01	
	7		UNION-ALL													
*	8		INDEX FAST FULL SCAN		EMP_MANAGER_IX		10106		40424		18		(0)		00:00:01	
*	9		TABLE ACCESS FULL		DEPARTMENTS		11		33		3		(0)		00:00:01	

Predicate Information (identified by operation id):

```

2 - filter(COUNT(*)>=3)
4 - access("EMPLOYEES"."EMPLOYEE_ID"="MANAGER_IDS"."MANAGER_ID")
8 - filter("MANAGER_ID" IS NOT NULL)
9 - filter("MANAGER_ID" IS NOT NULL)

```

Statistics

```

526 recursive calls
0 db block gets
1189 consistent gets
420 physical reads
0 redo size
2023 bytes sent via SQL*Net to client
96 bytes received via SQL*Net from client
6 SQL*Net roundtrips to/from client
68 sorts (memory)
0 sorts (disk)
68 rows processed

```

Рис.2.3. План выполнения запроса

2.3. Первая оптимизация (переписывание запроса)

Попробуем использовать вместо MINUS оператор NOT EXISTS с подзапросом (рис.2.4).

```

SELECT upper_employees.first_name
FROM hr.employees upper_employees
WHERE NOT EXISTS (
  SELECT hr.employees.first_name
  FROM hr.employees
  JOIN (
    SELECT manager_id
    FROM hr.employees
    WHERE manager_id IS NOT NULL
    UNION ALL
    SELECT manager_id
    FROM hr.departments
    WHERE manager_id IS NOT NULL
  ) manager_ids
  ON hr.employees.employee_id = manager_ids.manager_id
  WHERE hr.employees.first_name = upper_employees.first_name
)

```

```
GROUP BY upper_employees.first_name
HAVING COUNT(*) >= 3;
```

Рис.2.4. Переписанный запрос

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0	SELECT STATEMENT		2	28	105 (2)	00:00:01
* 1	HASH GROUP BY		2	28	105 (2)	00:00:01
* 2	HASH JOIN RIGHT ANTI		7552	103K	104 (1)	00:00:01
3	VIEW	VW_SQ_1	23	161	90 (2)	00:00:01
* 4	HASH JOIN SEMI		23	575	90 (2)	00:00:01
5	TABLE ACCESS FULL	EMPLOYEES	10107	118K	68 (0)	00:00:01
6	VIEW		10117	128K	21 (0)	00:00:01
7	UNION-ALL					
* 8	INDEX FAST FULL SCAN	EMP_MANAGER_IX	10106	40424	18 (0)	00:00:01
* 9	TABLE ACCESS FULL	DEPARTMENTS	11	33	3 (0)	00:00:01
10	INDEX FAST FULL SCAN	EMP_NAME_IX	10107	70749	14 (0)	00:00:01

Predicate Information (identified by operation id):

```
1 - filter(COUNT(*)>=3)
2 - access("ITEM_1"="UPPER_EMPLOYEES"."FIRST_NAME")
4 - access("EMPLOYEES"."EMPLOYEE_ID"="MANAGER_IDS"."MANAGER_ID")
8 - filter("MANAGER_ID" IS NOT NULL)
9 - filter("MANAGER_ID" IS NOT NULL)
```

Statistics

```
526 recursive calls
0 db block gets
1189 consistent gets
420 physical reads
0 redo size
2023 bytes sent via SQL*Net to client
96 bytes received via SQL*Net from client
6 SQL*Net roundtrips to/from client
68 sorts (memory)
0 sorts (disk)
68 rows processed
```

Рис.2.5. План выполнения переписанного запроса

Смотрим, как изменился план. Стоимость (cost) уменьшилась довольно незначительно — на $\sim 2\%$ ($107 \rightarrow 105$). Статистики же не изменились никоим образом.

2.4. Вторая оптимизация (материализованное представление)

Попробуем более масштабную оптимизацию — создадим материализованное представление. Оно может очень сильно ускорить запрос. Недостатком, тем не менее, является то, что данные в представлении нужно поддерживать (при изменении данных в исходной таблице), однако таблица employees маловероятно будет меняться часто (так как сотрудники в компании не приходят и уходят каждую

минуту), может быть и такое, что таблица может не меняться днями. Поэтому использование материализованного представления здесь вполне оправдано.

Создание материализованного представления показано на рис.2.6.

```
CREATE MATERIALIZED VIEW employees_names_mview
BUILD IMMEDIATE
REFRESH COMPLETE
AS /* ИСХОДНЫЙ ЗАПРОС */
```

Рис.2.6. Создание материализованного представления employees_names_mview

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0	SELECT STATEMENT		68	476	3 (0)	00:00:01
1	MAT_VIEW ACCESS FULL	EMPLOYEES_NAMES_MVIEW	68	476	3 (0)	00:00:01

Statistics

```
934 recursive calls
0 db block gets
1460 consistent gets
96 physical reads
0 redo size
2239 bytes sent via SQL*Net to client
96 bytes received via SQL*Net from client
6 SQL*Net roundtrips to/from client
81 sorts (memory)
0 sorts (disk)
68 rows processed
```

Рис.2.7. План выполнения материализованного представления

Глядя на план, можно увидеть, как сильно изменился cost — на $\sim 97\%$ ($107 \rightarrow 3$). Некоторые статистики, тем не менее, ухудшились (кроме physical reads — они улучшились):

- recursive calls — $526 \rightarrow 934$,
- consistent gets — $1189 \rightarrow 1460$,
- physical reads — $420 \rightarrow 96$,
- bytes sent via SQL*Net to client — $2023 \rightarrow 2239$,
- sorts (memory) — $68 \rightarrow 81$.

ГЛАВА 3. ЗАДАЧА «ВЫВОД ГРУПП С ОТЛИЧНИКАМИ И ДОЛЖНИКАМИ (STUDENT)»

3.1. Описание задачи

Используются таблицы схемы STUDENT. Создать запрос для получения информации о группах в виде, представленном в таблице 3.1.

Таблица 3.1

Требуемый вывод для задачи №3

Группа	Кол-во студентов	Название специальности	Кол-во круглых отличников	Кол-во должников
121				
122				
...				

При подсчёте отличников учесть, что пятёрка могла быть получена со второй попытки. Для всех учитывать только экзамены, предусмотренные учебным планом.

3.2. Составленный запрос

```
WITH
groups_with_students AS (
  SELECT
    student.study_group.group_num,
    student.speciality.spec_title,
    COUNT(student.student.stud_num) AS students_count
  FROM
    student.study_group
    JOIN student.speciality
      ON student.study_group.spec_num = student.speciality.spec_num
    LEFT JOIN student.student
      ON student.study_group.group_num = student.student.group_num
  GROUP BY
    student.study_group.group_num,
    student.speciality.spec_title
),
student_courses AS (
  SELECT
    student.study_group.group_num,
```

```

        student.student.stud_num,
        student.curriculum.course_num
    FROM student.student
        JOIN student.study_group
            ON student.study_group.group_num = student.student.group_num
        JOIN student.curriculum
            ON student.study_group.spec_num = student.curriculum.spec_num
    ),
    correct_grades AS (
        SELECT
            student_courses.group_num,
            student.grades.stud_num,
            student.grades.course_num,
            FIRST_VALUE(student.grades.grade)
                OVER (
                    PARTITION BY student.grades.stud_num, student.grades.course_num
                    ORDER BY student.grades.exam_date DESC
                )
                AS last_grade
        FROM student.grades
            JOIN student_courses
                ON student.grades.stud_num = student_courses.stud_num
                AND student.grades.course_num = student_courses.course_num
    ),
    min_grades AS (
        SELECT
            group_num,
            stud_num,
            MIN(last_grade) AS min_grade
        FROM correct_grades
        GROUP BY group_num, stud_num
    )
    SELECT
        groups_with_students.group_num AS "Группа",
        groups_with_students.students_count AS "Кол-во студентов",
        groups_with_students.spec_title AS "Кол-во студентов",
        COUNT(CASE WHEN min_grades.min_grade = 5 THEN 1 END) AS "Кол-во круглых отличников",
        COUNT(CASE WHEN min_grades.min_grade = 2 THEN 1 END) AS "Кол-во должников"
    FROM groups_with_students
        LEFT JOIN min_grades
            ON min_grades.group_num = groups_with_students.group_num
    GROUP BY
        groups_with_students.group_num,
        groups_with_students.students_count,
        groups_with_students.spec_title;

```

Рис.3.1. Запрос для задачи №3

Группа	Кол-во студентов	Кол-во студентов	Кол-во круглых отличников	Кол-во должников
121		3 СИСТЕМЫ АВТОМАТИЧЕСКОГО УПРАВЛЕНИЯ	1	1
122		2 СИСТЕМЫ АВТОМАТИЧЕСКОГО УПРАВЛЕНИЯ	1	0
123		2 ЭКОНОМИКА ПРЕДПРИЯТИЙ	0	1
124		2 ЭКОНОМИКА ПРЕДПРИЯТИЙ	0	0

Рис.3.2. Результат запроса

Id	Operation	Name	Rows	Bytes	TempSpc	Cost (%CPU)	Time
0	SELECT STATEMENT		1898	170K		373 (4)	00:00:01
1	HASH GROUP BY		1898	170K		373 (4)	00:00:01
* 2	HASH JOIN OUTER		47128	4234K		370 (3)	00:00:01
3	VIEW		1898	137K		77 (6)	00:00:01
4	HASH GROUP BY		1898	140K		77 (6)	00:00:01
* 5	HASH JOIN OUTER		19983	1483K		75 (3)	00:00:01
6	MERGE JOIN		671	44286		6 (17)	00:00:01
7	TABLE ACCESS BY INDEX ROWID	SPECIALITY	4	236		2 (0)	00:00:01
8	INDEX FULL SCAN	SYS_C0010097	4			1 (0)	00:00:01
* 9	SORT JOIN		671	4697		4 (25)	00:00:01
10	TABLE ACCESS FULL	STUDY_GROUP	671	4697		3 (0)	00:00:01
11	TABLE ACCESS FULL	STUDENT	19983	195K		68 (0)	00:00:01
12	VIEW		16661	292K		293 (2)	00:00:01
13	HASH GROUP BY		16661	113K		293 (2)	00:00:01
14	VIEW		16661	113K		291 (2)	00:00:01
15	WINDOW SORT		16661	715K	864K	291 (2)	00:00:01
* 16	HASH JOIN		16661	715K		101 (2)	00:00:01
17	INDEX FULL SCAN	PK_UCHEB	5	35		1 (0)	00:00:01
* 18	HASH JOIN		22411	809K		99 (2)	00:00:01
* 19	HASH JOIN		19983	331K		72 (2)	00:00:01
20	TABLE ACCESS FULL	STUDY_GROUP	671	4697		3 (0)	00:00:01
21	TABLE ACCESS FULL	STUDENT	19983	195K		68 (0)	00:00:01
22	TABLE ACCESS FULL	GRADES	22430	438K		27 (0)	00:00:01

Predicate Information (identified by operation id):

```

2 - access("MIN_GRADES"."GROUP_NUM" (+)= "GROUPS_WITH_STUDENTS"."GROUP_NUM")
5 - access("STUDY_GROUP"."GROUP_NUM" = "STUDENT"."GROUP_NUM" (+))
9 - access("STUDY_GROUP"."SPEC_NUM" = "SPECIALITY"."SPEC_NUM")
  filter("STUDY_GROUP"."SPEC_NUM" = "SPECIALITY"."SPEC_NUM")
16 - access("GRADES"."COURSE_NUM" = "CURRICULUM"."COURSE_NUM" AND
  "STUDY_GROUP"."SPEC_NUM" = "CURRICULUM"."SPEC_NUM")
18 - access("GRADES"."STUD_NUM" = "STUDENT"."STUD_NUM")
19 - access("STUDY_GROUP"."GROUP_NUM" = "STUDENT"."GROUP_NUM")

```

Statistics

```

2471 recursive calls
23 db block gets
4264 consistent gets
610 physical reads
4052 redo size
38650 bytes sent via SQL*Net to client
536 bytes received via SQL*Net from client
46 SQL*Net roundtrips to/from client
246 sorts (memory)
0 sorts (disk)
671 rows processed

```

Рис.3.3. План выполнения запроса

3.3. Первая оптимизация (bitmap индекс)

Заметим, что в таблице student столбец group_num имеет тенденцию хранить похожие значения (так как для каждой группы N -ое количество студентов учится в ней). Отсюда делаем вывод, что логично было бы создать bitmap индекс на этот столбец, что мы и сделаем.

Id	Operation	Name	Rows	Bytes	TempSpc	Cost (%CPU)	Time
0	SELECT STATEMENT		1898	170K		338 (4)	00:00:01
1	HASH GROUP BY		1898	170K		338 (4)	00:00:01
* 2	HASH JOIN OUTER		47128	4234K		335 (3)	00:00:01
3	VIEW		1898	137K		59 (7)	00:00:01
4	HASH GROUP BY		1898	140K		59 (7)	00:00:01
* 5	HASH JOIN OUTER		19983	1483K		57 (4)	00:00:01
6	MERGE JOIN		671	44286		6 (17)	00:00:01
7	TABLE ACCESS BY INDEX ROWID	SPECIALITY	4	236		2 (0)	00:00:01
8	INDEX FULL SCAN	SYS_C0010097	4			1 (0)	00:00:01
* 9	SORT JOIN		671	4697		4 (25)	00:00:01
10	TABLE ACCESS FULL	STUDY_GROUP	671	4697		3 (0)	00:00:01
11	VIEW	index\$_join\$_004	19983	195K		51 (2)	00:00:01
* 12	HASH JOIN						
13	BITMAP CONVERSION TO ROWIDS		19983	195K		11 (0)	00:00:01
14	BITMAP INDEX FULL SCAN	STUDENT_GROUP_NUM_IDX					
15	INDEX FAST FULL SCAN	SYS_C0010070	19983	195K		49 (0)	00:00:01
16	VIEW		16661	292K		276 (3)	00:00:01
17	HASH GROUP BY		16661	113K		276 (3)	00:00:01
18	VIEW		16661	113K		274 (2)	00:00:01
19	WINDOW SORT		16661	715K	864K	274 (2)	00:00:01
* 20	HASH JOIN		16661	715K		83 (3)	00:00:01
21	INDEX FULL SCAN	PK_UCHEB	5	35		1 (0)	00:00:01
* 22	HASH JOIN		22411	809K		82 (3)	00:00:01
* 23	HASH JOIN		19983	331K		54 (2)	00:00:01
24	TABLE ACCESS FULL	STUDY_GROUP	671	4697		3 (0)	00:00:01
25	VIEW	index\$_join\$_006	19983	195K		51 (2)	00:00:01
* 26	HASH JOIN						
27	BITMAP CONVERSION TO ROWIDS		19983	195K		11 (0)	00:00:01
28	BITMAP INDEX FULL SCAN	STUDENT_GROUP_NUM_IDX					
29	INDEX FAST FULL SCAN	SYS_C0010070	19983	195K		49 (0)	00:00:01
30	TABLE ACCESS FULL	GRADES	22430	438K		27 (0)	00:00:01

Predicate Information (identified by operation id):

```

2 - access("MIN_GRADES"."GROUP_NUM"(+)="GROUPS_WITH_STUDENTS"."GROUP_NUM")
5 - access("STUDY_GROUP"."GROUP_NUM"="STUDENT"."GROUP_NUM"(+))
9 - access("STUDY_GROUP"."SPEC_NUM"="SPECIALITY"."SPEC_NUM")
  filter("STUDY_GROUP"."SPEC_NUM"="SPECIALITY"."SPEC_NUM")
12 - access(ROWID=ROWID)
20 - access("GRADES"."COURSE_NUM"="CURRICULUM"."COURSE_NUM" AND
  "STUDY_GROUP"."SPEC_NUM"="CURRICULUM"."SPEC_NUM")
22 - access("GRADES"."STUD_NUM"="STUDENT"."STUD_NUM")
23 - access("STUDY_GROUP"."GROUP_NUM"="STUDENT"."GROUP_NUM")
26 - access(ROWID=ROWID)

```

Statistics

```

2446 recursive calls
22 db block gets
3852 consistent gets
414 physical reads
3832 redo size
38650 bytes sent via SQL*Net to client
536 bytes received via SQL*Net from client
46 SQL*Net roundtrips to/from client
242 sorts (memory)
0 sorts (disk)
671 rows processed

```

Рис.3.4. План выполнения оптимизированного запроса

Смотрим план выполнения. Наблюдаем уменьшение стоимости (cost) запроса — на ~ 10% (373 → 338). Посмотрим, как поменялись статистики (в лучшую сторону):

- recursive calls — 2471 → 2446,
- db block gets — 23 → 22,
- consistent gets — 4264 → 3852,
- physical reads — 610 → 414,
- redo size — 4052 → 3832,
- sorts (memory) — 246 → 242.

3.4. Вторая оптимизация (индексно-организованная таблица)

Обратим внимание на таблицу student — в ней нам нужны лишь поля stud_num и group_num. Так как остальные поля не используются, логично создать индексно-организованную таблицу student_lookup (рис.3.5).

```
DROP TABLE student_lookup PURGE;
CREATE TABLE student_lookup (
    stud_num,
    group_num,
    CONSTRAINT student_lookup_pk PRIMARY KEY (stud_num)
)
ORGANIZATION INDEX
AS
SELECT stud_num, group_num
FROM student.student;
```

Рис.3.5. Создание индексно-организованной таблицы student_lookup

После чего в исходном запросе (рис.3.1) нам необходимо изменить все вхождения student.student на student.student_lookup (для краткости изложения, код приводиться не будет, так как нужно поменять всего лишь 2 строки).

Id	Operation	Name	Rows	Bytes	TempSpc	Cost (%CPU)	Time	
0	SELECT STATEMENT		1898	170K		324 (5)	00:00:01	
1	HASH GROUP BY		1898	170K		324 (5)	00:00:01	
* 2	HASH JOIN OUTER		47128	4234K		321 (4)	00:00:01	
3	VIEW		1898	137K		24 (13)	00:00:01	
4	HASH GROUP BY		1898	177K		24 (13)	00:00:01	
* 5	HASH JOIN OUTER		19983	1873K		22 (5)	00:00:01	
6	MERGE JOIN		671	44286		6 (17)	00:00:01	
7	TABLE ACCESS BY INDEX ROWID	SPECIALITY	4	236		2 (0)	00:00:01	
8	INDEX FULL SCAN	SYS_C0010097	4			1 (0)	00:00:01	
* 9	SORT JOIN		671	4697		4 (25)	00:00:01	
10	TABLE ACCESS FULL	STUDY_GROUP	671	4697		3 (0)	00:00:01	
11	INDEX FAST FULL SCAN	STUDENT_LOOKUP_PK	19983	585K		16 (0)	00:00:01	
12	VIEW		16661	292K		296 (3)	00:00:01	
13	HASH GROUP BY		16661	113K		296 (3)	00:00:01	
14	VIEW		16661	113K		295 (3)	00:00:01	
15	WINDOW SORT		16661	1041K	1192K	295 (3)	00:00:01	
* 16	HASH JOIN		16661	1041K		35 (12)	00:00:01	

17	INDEX FULL SCAN	PK_UCHEB	5	35	1 (0)	00:00:01
* 18	HASH JOIN		22411	1247K	33 (10)	00:00:01
19	TABLE ACCESS FULL	STUDY_GROUP	671	4697	3 (0)	00:00:01
20	NESTED LOOPS		22411	1094K	30 (10)	00:00:01
21	TABLE ACCESS FULL	GRADES	22430	438K	27 (0)	00:00:01
* 22	INDEX UNIQUE SCAN	STUDENT_LOOKUP_PK	1	30	0 (0)	00:00:01

Predicate Information (identified by operation id):

```

2 - access("MIN_GRADES"."GROUP_NUM"(+)="GROUPS_WITH_STUDENTS"."GROUP_NUM")
5 - access("STUDY_GROUP"."GROUP_NUM"="STUDENT_LOOKUP"."GROUP_NUM"(+))
9 - access("STUDY_GROUP"."SPEC_NUM"="SPECIALITY"."SPEC_NUM")
  filter("STUDY_GROUP"."SPEC_NUM"="SPECIALITY"."SPEC_NUM")
16 - access("GRADES"."COURSE_NUM"="CURRICULUM"."COURSE_NUM" AND
  "STUDY_GROUP"."SPEC_NUM"="CURRICULUM"."SPEC_NUM")
18 - access("STUDY_GROUP"."GROUP_NUM"="STUDENT_LOOKUP"."GROUP_NUM")
22 - access("GRADES"."STUD_NUM"="STUDENT_LOOKUP"."STUD_NUM")

```

Note

```

-----
- dynamic statistics used: dynamic sampling (level=2)

```

Statistics

```

-----
2441 recursive calls
23 db block gets
4389 consistent gets
404 physical reads
3832 redo size
38650 bytes sent via SQL*Net to client
536 bytes received via SQL*Net from client
46 SQL*Net roundtrips to/from client
242 sorts (memory)
0 sorts (disk)
671 rows processed

```

Рис.3.6. План выполнения оптимизированного запроса

Посмотрим на план выполнения. Видим уменьшение стоимости (cost) запроса — на ~ 13% (373 → 324). Посмотрим, как поменялись статистики (в лучшую сторону, за исключением consistent gets):

- recursive calls — 2471 → 2441,
- consistent gets — 4264 → 4389,
- physical reads — 610 → 404,
- redo size — 4052 → 3832,
- sorts (memory) — 246 → 242.

ГЛАВА 4. ЗАДАЧА «КЛИЕНТ, СДЕЛАВШИЙ ПОКУПКУ НА МАКСИМАЛЬНУЮ СУММУ (SH)»

4.1. Описание задачи

Используются таблицы схемы SH. Вывести фамилию и имя клиента, сделавшего покупки через интернет (channel_desc = "Internet") или партнёров (channel_desc = "Partners") не по акции (promo_category = "NO PROMOTION #") на максимальную сумму в заданном году.

4.2. Составленный запрос

```
SELECT
  sh.customers.cust_last_name AS "Surname",
  sh.customers.cust_first_name AS "Name",
  SUM(sh.sales.amount_sold * sh.sales.quantity_sold) AS "Spent"
FROM sh.sales
  JOIN sh.customers
    ON sh.sales.cust_id = sh.customers.cust_id
  JOIN sh.channels
    ON sh.sales.channel_id = sh.channels.channel_id
  JOIN sh.promotions
    ON sh.sales.promo_id = sh.promotions.promo_id
WHERE
  sh.channels.channel_desc IN ('Internet', 'Partners')
  AND sh.promotions.promo_name = 'NO PROMOTION #'
  AND TRUNC(sh.sales.time_id, 'YEAR')
    = TRUNC(TO_DATE('1998', 'yyyy'), 'YEAR')
GROUP BY
  sh.customers.cust_id,
  sh.customers.cust_first_name,
  sh.customers.cust_last_name
ORDER BY "Spent" DESC
FETCH FIRST 1 ROWS ONLY;
```

Рис.4.1. Запрос для задачи №4

Surname	Name	Spent
Bakerman	Marvel	56243,93

Рис.4.2. Результат запроса для года 1998

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time	Pstart	Pstop
0	SELECT STATEMENT		1	73	1059 (11)	00:00:01		
1	SORT ORDER BY		1	73	1059 (11)	00:00:01		
* 2	VIEW		1	73	1058 (11)	00:00:01		
* 3	WINDOW SORT PUSHED RANK		1149	100K	1058 (11)	00:00:01		
4	HASH GROUP BY		1149	100K	1058 (11)	00:00:01		
* 5	HASH JOIN		1149	100K	1056 (11)	00:00:01		
* 6	HASH JOIN		1149	80430	632 (17)	00:00:01		
7	MERGE JOIN CARTESIAN		2	84	20 (0)	00:00:01		
* 8	TABLE ACCESS FULL	PROMOTIONS	1	29	17 (0)	00:00:01		
9	BUFFER SORT		2	26	3 (0)	00:00:01		
* 10	TABLE ACCESS FULL	CHANNELS	2	26	3 (0)	00:00:01		
11	PARTITION RANGE ALL		9188	251K	612 (17)	00:00:01	1	28
* 12	TABLE ACCESS FULL	SALES	9188	251K	612 (17)	00:00:01	1	28
13	TABLE ACCESS FULL	CUSTOMERS	55500	1083K	423 (1)	00:00:01		

Predicate Information (identified by operation id):

```

2 - filter("from$_subquery$_008"."rowlimit_$$_rownumber"<=1)
3 - filter(ROW_NUMBER() OVER ( ORDER BY SUM("SALES"."AMOUNT_SOLD"*"SALES"."QUANTITY_SOLD")
    DESC )<=1)
5 - access("SALES"."CUST_ID"="CUSTOMERS"."CUST_ID")
6 - access("SALES"."PROMO_ID"="PROMOTIONS"."PROMO_ID" AND
    "SALES"."CHANNEL_ID"="CHANNELS"."CHANNEL_ID")
8 - filter("PROMOTIONS"."PROMO_NAME"='NO PROMOTION #')
10 - filter("CHANNELS"."CHANNEL_DESC"='Internet' OR "CHANNELS"."CHANNEL_DESC"='Partners')
12 - filter(TRUNC(INTERNAL_FUNCTION("SALES"."TIME_ID"),'fmyear')=TRUNC(TO_DATE('1998','yyyy'),'
    fmyear'))

```

Statistics

```

4230 recursive calls
4 db block gets
10016 consistent gets
3582 physical reads
792 redo size
735 bytes sent via SQL*Net to client
52 bytes received via SQL*Net from client
2 SQL*Net roundtrips to/from client
374 sorts (memory)
0 sorts (disk)
1 rows processed

```

Рис.4.3. План выполнения запроса

4.3. Первая оптимизация (индексно-организованная таблица)

В таблице customers довольно большое количество столбцов (больше 10), однако в нашем запросе используются лишь 3, отсюда появляется идея создать индексно-организованную таблицу customer_lookup, содержащую эти столбцы. Это мы и сделаем (рис.4.4).

```

CREATE TABLE customer_lookup (
  cust_id,
  cust_last_name,
  cust_first_name,
  CONSTRAINT customers_iot_pk PRIMARY KEY (cust_id)
)
ORGANIZATION INDEX
AS
SELECT
  cust_id,
  cust_last_name,

```

```

cust_first_name
FROM sh.customers;

```

Рис.4.4. Создание индексно-организованной таблицы customer_lookup

Как и в предыдущей задаче, нам нужно всего лишь заменить все вхождения sh.customer на sh.customer_lookup.

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time	Pstart	Pstop
0	SELECT STATEMENT		1	73	635 (17)	00:00:01		
1	SORT ORDER BY		1	73	635 (17)	00:00:01		
* 2	VIEW		1	73	634 (17)	00:00:01		
* 3	WINDOW SORT PUSHED RANK		1149	131K	634 (17)	00:00:01		
4	HASH GROUP BY		1149	131K	634 (17)	00:00:01		
5	NESTED LOOPS		1149	131K	632 (17)	00:00:01		
* 6	HASH JOIN		1149	80430	632 (17)	00:00:01		
7	MERGE JOIN CARTESIAN		2	84	20 (0)	00:00:01		
* 8	TABLE ACCESS FULL	PROMOTIONS	1	29	17 (0)	00:00:01		
9	BUFFER SORT		2	26	3 (0)	00:00:01		
* 10	TABLE ACCESS FULL	CHANNELS	2	26	3 (0)	00:00:01		
11	PARTITION RANGE ALL		9188	251K	612 (17)	00:00:01	1	28
* 12	TABLE ACCESS FULL	SALES	9188	251K	612 (17)	00:00:01	1	28
* 13	INDEX UNIQUE SCAN	CUSTOMERS_IOT_PK	1	47	0 (0)	00:00:01		

Predicate Information (identified by operation id):

```

2 - filter("from$_subquery$_008"."rowlimit_$$_rownumber"<=1)
3 - filter(ROW_NUMBER() OVER ( ORDER BY SUM("SALES"."AMOUNT_SOLD"*"SALES"."QUANTITY_SOLD") DESC
    )<=1)
6 - access("SALES"."PROMO_ID"="PROMOTIONS"."PROMO_ID" AND
    "SALES"."CHANNEL_ID"="CHANNELS"."CHANNEL_ID")
8 - filter("PROMOTIONS"."PROMO_NAME"='NO PROMOTION #')
10 - filter("CHANNELS"."CHANNEL_DESC"='Internet' OR "CHANNELS"."CHANNEL_DESC"='Partners')
12 - filter(TRUNC(INTERNAL_FUNCTION("SALES"."TIME_ID"),'fmyear')=TRUNC(TO_DATE('1998','yyyy'),'fmyear'
    ))
13 - access("SALES"."CUST_ID"="CUSTOMER_LOOKUP"."CUST_ID")

```

Note

```

- dynamic statistics used: dynamic sampling (level=2)

```

Statistics

```

2227 recursive calls
0 db block gets
52689 consistent gets
2054 physical reads
0 redo size
735 bytes sent via SQL*Net to client
52 bytes received via SQL*Net from client
2 SQL*Net roundtrips to/from client
197 sorts (memory)
0 sorts (disk)
1 rows processed

```

Рис.4.5. План выполнения оптимизированного запроса

Как можно заметить на плане, стоимость запроса существенно снизилась — на ~ 40% (1059 → 635). Посмотрим на изменение статистик (многие статистики улучшились, причём некоторые — довольно ощутимо, — хотя некоторые, всё же ухудшились, особенно consistent gets):

– recursive calls — 2471 → 2227,

- db block gets — 23 → 0,
- consistent gets — 4264 → 52689,
- physical reads — 610 → 2054,
- redo size — 4052 → 0,
- bytes sent via SQL*Net to client — 38650 → 735,
- bytes received via SQL*Net from client — 536 → 52,
- SQL*Net roundtrips to/from client — 46 → 2,
- sorts (memory) — 246 → 197,
- rows processed — 671 → 1.

4.4. Вторая оптимизация (компазитный B-tree индекс)

Есть также другой путь оптимизации 3-х столбцов из предыдущей оптимизации — заметим, что все эти столбцы находятся внутри GROUP BY, что как бы намекает нам на создание композитного B-tree индекса (B-tree потому, что значения не имеют тенденции иметь много одинаковых значений). Этим мы и займёмся — создадим такой индекс (рис.4.6).

```
CREATE INDEX customers_cmpidx ON sh.customers (cust_id, cust_first_name, cust_last_name);
```

Рис.4.6. Создание композитного индекса

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time	Pstart	Pstop
0	SELECT STATEMENT		1	73	700 (16)	00:00:01		
1	SORT ORDER BY		1	73	700 (16)	00:00:01		
* 2	VIEW		1	73	699 (16)	00:00:01		
* 3	WINDOW SORT PUSHED RANK		7059	620K	699 (16)	00:00:01		
4	HASH GROUP BY		7059	620K	699 (16)	00:00:01		
* 5	HASH JOIN		1149	100K	697 (16)	00:00:01		
* 6	HASH JOIN		1149	80430	632 (17)	00:00:01		
7	MERGE JOIN CARTESIAN		2	84	20 (0)	00:00:01		
* 8	TABLE ACCESS FULL	PROMOTIONS	1	29	17 (0)	00:00:01		
9	BUFFER SORT		2	26	3 (0)	00:00:01		
* 10	TABLE ACCESS FULL	CHANNELS	2	26	3 (0)	00:00:01		
11	PARTITION RANGE ALL		9188	251K	612 (17)	00:00:01	1	28
* 12	TABLE ACCESS FULL	SALES	9188	251K	612 (17)	00:00:01	1	28
13	INDEX FAST FULL SCAN	CUSTOMERS_CMPIDX	55500	1083K	65 (2)	00:00:01		

Predicate Information (identified by operation id):

```

2 - filter("from$_subquery$008"."rowlimit_$$_rownumber"<=1)
3 - filter(ROW_NUMBER() OVER ( ORDER BY SUM("SALES"."AMOUNT_SOLD"*"SALES"."QUANTITY_SOLD") DESC
) <=1)
5 - access("SALES"."CUST_ID"="CUSTOMERS"."CUST_ID")
6 - access("SALES"."PROMO_ID"="PROMOTIONS"."PROMO_ID" AND
"SALES"."CHANNEL_ID"="CHANNELS"."CHANNEL_ID")
8 - filter("PROMOTIONS"."PROMO_NAME"='NO PROMOTION #')
10 - filter("CHANNELS"."CHANNEL_DESC"='Internet' OR "CHANNELS"."CHANNEL_DESC"='Partners')
12 - filter(TRUNC(INTERNAL_FUNCTION("SALES"."TIME_ID"),'fmyear')=TRUNC(TO_DATE('1998','yyyy'),'fmyear
'))

```

Statistics

```

-----
4217 recursive calls
  4 db block gets
8701 consistent gets
2286 physical reads
 792 redo size
 735 bytes sent via SQL*Net to client
   52 bytes received via SQL*Net from client
    2 SQL*Net roundtrips to/from client
 370 sorts (memory)
    0 sorts (disk)
    1 rows processed

```

Рис.4.7. План выполнения оптимизированного запроса

Теперь посмотрим, как изменился cost. Улучшение поменьше, чем при первой оптимизации — на $\sim 34\%$ ($1059 \rightarrow 700$), — однако плюсом этой оптимизации является то, что нам не нужно поддерживать отдельную таблицу `sh.customer_lookup`, хотя и нужно поддерживать индекс, при этом прошлая оптимизация работает лишь для `sh.customer_lookup`, текущая — для изначальной таблицы. Посмотрим на статистики (здесь, по сравнению с прошлой оптимизацией, не произошло ухудшения статистик, однако и улучшения не столь значительны):

- recursive calls — $4230 \rightarrow 4217$,
- consistent gets — $10016 \rightarrow 8701$,
- physical reads — $3582 \rightarrow 2286$,
- sorts (memory) — $374 \rightarrow 370$.

ГЛАВА 5. ЗАДАЧА «СПИСОК СОТРУДНИКОВ ПО ДОЛЖНОСТЯМ И ЗАРПЛАТАМ (HR)»

5.1. Описание задачи

Используются таблицы схемы HR. Одной командой SELECT вывести список сотрудников компании, имеющих коллег с таким же идентификатором должности и окладом. Если некоторый идентификатор должности и размер оклада имеет один единственный сотрудник, то сведения о нём в результат попадать не должны.

В результат вывести:

1. идентификатор должности;
2. размер оклада;
3. список фамилий сотрудников, имеющих данный идентификатор должности и данный оклад.

Фамилии в списке должны быть:

- a. упорядочены по алфавиту (по возрастанию),
- b. разделены символами ' , ' («запятая» и «пробел»),
- c. перед первой фамилией не должно быть символов-разделителей,
- d. после последней фамилии символов-разделителей быть не должно.

Результат упорядочить:

1. по размеру оклада (по убыванию),
2. по идентификатору должности (по возрастанию).

5.2. Составленный запрос

```
SELECT
  job_id AS "Job ID",
  salary AS "Salary",
  -- CAST нужен для того, чтобы список помещался в одну строчку.
  CAST(
    LISTAGG(last_name, ' , ')
    WITHIN GROUP (ORDER BY last_name)
    AS VARCHAR2(64)
  ) AS "Surnames"
FROM hr.employees
GROUP BY job_id, salary
HAVING COUNT(*) > 1
ORDER BY "Salary" DESC, "Job ID";
```


Рис.5.1. Запрос для задачи №5

Job ID	Salary	Surnames
AD_VP	17000	De Haan, Kochhar
SA_REP	10000	Bloom, King, Tucker
SA_REP	9500	Bernstein, Greene, Sully
SA_REP	9000	Hall, McEwen
SA_REP	8000	Olsen, Smith
SA_REP	7500	Cambrault, Doran
SA_REP	7000	Grant, Sewall, Tuvault
SA_REP	6200	Banda, Johnson
IT_PROG	4800	Austin, Pataballa
ST_CLERK	3300	Bissot, Mallin
SH_CLERK	3200	McCain, Taylor

Job ID	Salary	Surnames
ST_CLERK	3200	Nayer, Stiles
SH_CLERK	3100	Fleaur, Walsh
SH_CLERK	3000	Cabrio, Feeney
SH_CLERK	2800	Geoni, Jones
ST_CLERK	2700	Mikkilineni, Seo
SH_CLERK	2600	Grant, OConnell
SH_CLERK	2500	Perkins, Sullivan
ST_CLERK	2500	Marlow, Patel, Vargas
ST_CLERK	2400	Gee, Landry
ST_CLERK	2200	Markle, Philtanker

Рис.5.2. Результат запроса

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0	SELECT STATEMENT		39	975	70 (3)	00:00:01
1	FILTER					
2	SORT GROUP BY		39	975	70 (3)	00:00:01
3	TABLE ACCESS FULL	EMPLOYEES	10107	246K	68 (0)	00:00:01

Predicate Information (identified by operation id):

1 - filter(COUNT(*)>1)

Statistics

469	recursive calls
0	db block gets
918	consistent gets
295	physical reads
0	redo size
100333	bytes sent via SQL*Net to client
855	bytes received via SQL*Net from client
75	SQL*Net roundtrips to/from client
49	sorts (memory)
0	sorts (disk)
1101	rows processed

Рис.5.3. План выполнения запроса

5.3. Первая оптимизация (материализованное представление)

Как мы уже обсуждали ранее, материализованное представление — довольно хороший выбор для таблицы `employees`, текущий запрос — не исключение (он возвращает не так много строк, поэтому представление будет небольшим). Создадим материализованное представление с помощью скрипта на рис.5.4.

```
CREATE MATERIALIZED VIEW employees_job_salary_mview
BUILD IMMEDIATE
REFRESH COMPLETE
AS /* ИСХОДНЫЙ ЗАПРОС */
```

Рис.5.4. Создание материализованного представления `employees_job_salary_mview`

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0	SELECT STATEMENT		1101	82575	6 (0)	00:00:01
1	MAT_VIEW ACCESS FULL	EMPLOYEES_JOB_SALARY_MVIEW	1101	82575	6 (0)	00:00:01

Statistics

```

954 recursive calls
18 db block gets
1576 consistent gets
113 physical reads
2940 redo size
103883 bytes sent via SQL*Net to client
855 bytes received via SQL*Net from client
75 SQL*Net roundtrips to/from client
84 sorts (memory)
0 sorts (disk)
1101 rows processed
```

Рис.5.5. План выполнения материализованного представления

Посмотрим на план выполнения. Видим, что очень заметно снизился cost — на ~ 91% (70 → 6). Однако большинство статистик ухудшилось:

- recursive calls — 469 → 954,
- db block gets — 0 → 18,
- consistent gets — 918 → 1576,
- physical reads — 295 → 113,
- redo size — 0 → 2940,
- bytes sent via SQL*Net to client — 100333 → 103883,
- sorts (memory) — 49 → 84.

5.4. Вторая оптимизация (компози́тный bitmap индекс)

Заметим, что в GROUP BY находятся 2 столбца — salary и job_id, что говорит нам о том, что неплохо было бы иметь на них компози́тный индекс. Создадим же компози́тный bitmap индекс (bitmap — потому что значения часто повторяются — иначе вряд ли есть смысл по ним группировать) — рис.5.6. Обратим внимание на DESC у salary — он используется потому, что в сортировке в исходном запросе мы сортируем по salary DESC (и, вообще говоря, довольно часто в запросах employees сортировка по salary идёт именно в обратном порядке).

```
CREATE BITMAP INDEX employees_salary_job_idx ON hr.employees (salary DESC, job_id);
```

Рис.5.6. Создание компози́тного bitmap индекса

Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0	SELECT STATEMENT		39	975	57 (4)	00:00:01
* 1	FILTER					
2	SORT GROUP BY		39	975	57 (4)	00:00:01
3	VIEW	index\$_join\$_001	10107	246K	55 (0)	00:00:01
* 4	HASH JOIN					
5	BITMAP CONVERSION TO ROWIDS		10107	246K	10 (0)	00:00:01
6	BITMAP INDEX FULL SCAN	EMPLOYEES_SALARY_JOB_IDX				
7	INDEX FAST FULL SCAN	EMP_NAME_IX	10107	246K	56 (0)	00:00:01

Predicate Information (identified by operation id):

```
1 - filter(COUNT(*)>1)
4 - access(ROWID=ROWID)
```

Statistics

```
506 recursive calls
12 db block gets
786 consistent gets
113 physical reads
2024 redo size
100333 bytes sent via SQL*Net to client
855 bytes received via SQL*Net from client
75 SQL*Net roundtrips to/from client
54 sorts (memory)
0 sorts (disk)
1101 rows processed
```

Рис.5.7. План выполнения оптимизированного запроса

Посмотрим, как эта оптимизация повлияла на план выполнения. В целом, неплохо уменьшилась стоимость (cost) — на $\sim 19\%$ ($70 \rightarrow 57$). Теперь посмотрим на изменение статистик (в целом, они ухудшились):

- recursive calls — $469 \rightarrow 506$,
- db block gets — $0 \rightarrow 12$,
- consistent gets — $918 \rightarrow 786$,
- physical reads — $295 \rightarrow 113$,
- redo size — $0 \rightarrow 2024$,
- sorts (memory) — $49 \rightarrow 54$.

ЗАКЛЮЧЕНИЕ

В данной работе было выполнено исследование различных способов оптимизации SQL-запросов на примере СУБД Oracle для 5-ти задач. Были написаны SQL-запросы для каждой задачи, были проанализированы планы выполнения, статистики и предложены по два варианта оптимизаций в каждой задаче. В ходе решения были использованы следующие способы оптимизации:

- function-based индекс,
- bitmap индекс,
- переписывание запроса,
- материализованное представление,
- индексно-организованная таблица,
- композитный B-tree индекс,
- композитный bitmap индекс.

В результате для каждого запроса удалось достигнуть снижения стоимости (cost). На протяжении всей работы была видна тенденция к ухудшению статистик (хотя и не везде) после оптимизаций. Объяснить это можно, вероятно, тем, что перед каждым запросом мы чистили shared pool и buffer cache, что могло негативно повлиять на запросы с индексами (по сравнению с тем, как если бы мы не чистили shared pool и buffer cache).

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Oracle DB sample schemas. — URL: <https://github.com/oracle/db-sample-schemas> (дата обращения: 13.11.2021).
2. Oracle portable database. — URL: <https://docs.oracle.com/database/121/CNCPT/cdbovrvw.htm#CNCPT89234> (дата обращения: 13.11.2021).
3. Using EXPLAIN PLAN. — URL: https://docs.oracle.com/cd/B10501_01/server.920/a96533/ex_plan.htm#19598 (дата обращения: 05.12.2021).
4. Репозиторий с данной работой. — URL: <https://github.com/Ruminat/coursework-optimizing-sql-queries> (дата обращения: 05.12.2021).
5. Схема STUDENT. — URL: <https://dl.spbstu.ru/mod/folder/view.php?id=145766> (дата обращения: 13.11.2021).